SINAPS: Tutor AI Adaptif untuk Menilai Interpretasi MRI Stroke Mahasiswa Kedokteran Berbasis Kunci Jawaban Tingkat Voxel

Rizzz
Timotius Christopher Patrick Sihombing[1*], Aqila Malfa Zahira[1], Radam Gumelar[1], Raphael Angelo Adikara Purnama[1]

[1]*Program Studi Sains Data, Universitas Airlangga, Surabaya, Indonesia*

***Abstrak*— Stroke menyebabkan 18,5% kematian di Indonesia, dan penanganannya sangat bergantung pada kemampuan dokter membaca citra otak. Meski begitu, mahasiswa kedokteran masih mempelajari keterampilan ini terutama dari gambar statis dan umpan balik radiolog, padahal Indonesia hanya memiliki sekitar 0,8 radiolog per 100.000 penduduk. Chatbot AI umum yang kini rutin dipakai mahasiswa juga belum andal membaca citra medis. Makalah ini mengusulkan SINAPS, tutor neuroradiologi berbasis web yang menggabungkan viewer MRI, model segmentasi lesi, penilaian otomatis terhadap kunci jawaban tingkat voxel, personalisasi dengan Bayesian Knowledge Tracing, dan tutor berbasis model bahasa multimodal yang hanya menjelaskan temuan terstruktur. Bank kasusnya berasal dari dataset terbuka SOOP yang mencakup 1.505 pasien stroke dengan 1.456 lesion mask. Uji kelayakan menunjukkan tiga hasil. U-Net 2.5D yang dilatih pada 250 pasien mencapai rerata Dice 0,78 (IK 95% 0,70 s.d. 0,85) pada 30 pasien uji. Aturan penilaian yang transparan mengenali lima jenis kesalahan anotasi dengan akurasi 84% pada subjek yang belum pernah dilihat, dibanding 41% bila hanya memakai Dice. Simulasi pemilihan kasus adaptif mengungguli urutan acak pada kedua belas skenario parameter (87% berbanding 61% kompetensi dikuasai setelah 60 kasus pada skenario dasar). Pada uji 30 kasus, pemberian temuan terstruktur menaikkan ketepatan klaim tutor dari 28% menjadi 100%, dan tutor yang diberi fakta tidak pernah ikut membenarkan jawaban keliru yang didesakkan mahasiswa.**

***Kata Kunci*— pendidikan kedokteran, pendidikan radiologi, sistem tutor cerdas, knowledge tracing, segmentasi lesi stroke, model bahasa multimodal.**

I. PENDAHULUAN

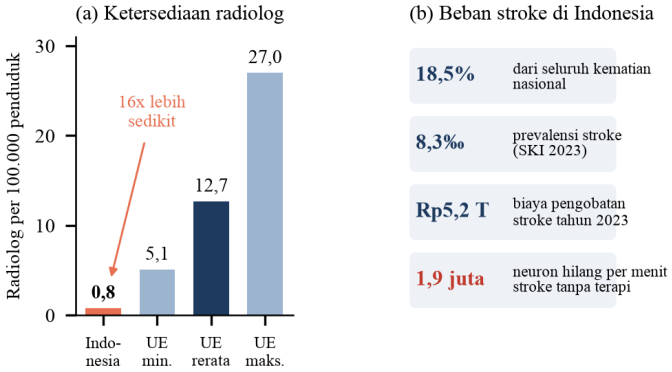
A. Latar Belakang

Membaca citra medis merupakan keterampilan yang dibutuhkan hampir semua dokter, bukan hanya radiolog [1]. Namun, cara mahasiswa kedokteran mempelajarinya masih jauh dari memadai. Survei terhadap 545 mahasiswa dari ke-17 fakultas kedokteran di Kanada menemukan bahwa kuliah didaktik adalah metode yang paling banyak dipakai (74%), dan 87% responden merasa paparan radiologinya kurang. Untuk setiap kelainan yang ditanyakan, kurang dari separuh responden yakin mampu menilainya [2]. Kondisi di Eropa serupa: radiologi hanya mendapat porsi kecil dalam kurikulum dan umumnya diajarkan lewat potongan gambar statis [1]. Di lingkungan dengan sumber daya terbatas, masalahnya lebih tajam. Survei tahun 2026 terhadap 431 mahasiswa klinik dan dokter internsip di Palestina mendapati hanya 43,2% yang menilai pendidikan radiologinya cukup dan hanya 26,9% yang yakin mampu membaca CT atau MRI kepala [3].

Kesenjangan ini penting karena interpretasi MRI adalah keterampilan prosedural, bukan hafalan visual. Mahasiswa harus menggulir puluhan slice, mengatur kontras, membandingkan DWI dengan peta ADC, lalu menandai batas lesi. Keterampilan semacam ini terbentuk melalui latihan terarah (*deliberate practice*) dengan umpan balik langsung [4], dan studi kurva belajar pada interpretasi radiografi menunjukkan bahwa kompetensi baru tercapai setelah ratusan kasus [5].

Di Indonesia, kekurangan pengajar memperparah kesenjangan tersebut. Rasio dokter nasional hanya 0,47 per 1.000 penduduk, peringkat ke-147 di dunia [6]. Jumlah radiolog terdaftar hanya 2.161 orang untuk sekitar 280 juta penduduk, atau kira-kira 0,8 per 100.000, dan sebagian besar terkumpul di Jawa dan Sumatra. Dengan sekitar 100 lulusan baru per tahun, dibutuhkan lebih dari satu abad untuk menyamai kepadatan radiolog Singapura [7]. Sebagai pembanding, rerata di 27 negara Uni Eropa adalah 12,7 per 100.000, dan negara terendah di kawasan itu pun masih memiliki 5,1 [8]. Radiolog yang sedikit ini harus membagi waktu antara pelayanan klinis dan mengajar, sehingga mustahil memberi setiap mahasiswa umpan balik pribadi atas ratusan kasus latihan (Gambar 1).

Kekurangan yang sama juga berdampak langsung pada pasien. Di luar pulau-pulau utama, dokter yang meminta pemeriksaan pencitraan stroke sering tidak bisa mengandalkan laporan radiolog yang tepat waktu, sehingga kemampuan membaca citra yang dipelajari semasa kuliah langsung terbawa ke pelayanan. Sejauh penelusuran kami, belum ada survei terpublikasi tentang penilaian mahasiswa kedokteran Indonesia terhadap pendidikan radiologinya sendiri. Karena itu, pengukuran kondisi awal tersebut menjadi kegiatan pertama dalam pilot kami (Subbab III.H).



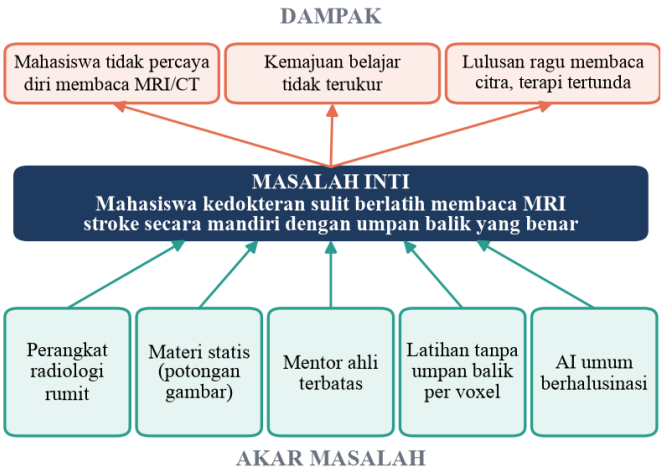
Gambar 1. Dua sisi permasalahan. (a) Kepadatan radiolog, yang sekaligus menjadi pengajar radiologi, di Indonesia dibanding Uni Eropa [7], [8]. (b) Beban stroke nasional dan tekanan waktu dalam penanganannya [9], [10].

Stroke dipilih sebagai domain latihan karena di sinilah pembacaan citra paling menentukan luaran pasien. Stroke adalah penyebab kematian kedua terbanyak di dunia [11] dan menyumbang 18,5% dari seluruh kematian di Indonesia [9], [12]. Setiap menit tanpa reperfusi, otak kehilangan sekitar 1,9 juta neuron [10]. Pencitraan otaklah yang membedakan infark dari perdarahan dan menentukan kelayakan trombolisis [13]. Di Indonesia, hanya sekitar 500 hingga 1.000 dari 150.000 hingga 200.000 pasien stroke per tahun yang mendapat trombolisis [14], sehingga setiap keterlambatan membaca citra yang bisa dihindari menjadi penting. Tata laksana awal stroke juga tercantum sebagai kompetensi dokter umum dalam Standar Kompetensi Dokter Indonesia [15]. Lulusan yang ragu membaca citra stroke dapat menunda keputusan terapi.

Pemilihan MRI sebagai titik awal perlu dijelaskan, sebab CT tanpa kontras masih menjadi pemeriksaan standar stroke di Indonesia dan baru 372 dari sekitar 3.200 rumah sakit yang memiliki CT scan [14]. Ada tiga alasan. Pertama, MRI difusi jauh lebih baik dalam menampilkan infark akut. Pada perbandingan prospektif terhadap 356 pasien gawat darurat, sensitivitas MRI untuk stroke akut mencapai 83% dibanding 26% pada CT, sedangkan untuk perdarahan keduanya setara [16]; neurolog Indonesia pun kini mendorong penggunaan MRI dalam jalur *code stroke* akut [14]. Kedua, infark dini sering tidak tampak pada CT sehingga mask CT tidak dapat dipakai untuk menilai mahasiswa secara adil, sedangkan mask DWI memberi kunci jawaban yang tegas. Ketiga, keterampilan yang dilatih (navigasi slice, windowing, teritori vaskular, delineasi) dapat dialihkan ke CT, dan tidak ada bagian platform yang terikat pada satu modalitas. Penambahan kasus CT termasuk dalam rencana lanjutan kami.

Pada saat yang sama, mahasiswa Indonesia termasuk pengguna AI generatif paling aktif di dunia. Survei Chegg 2025 terhadap 11.706 mahasiswa di 15 negara menempatkan Indonesia di urutan teratas, dengan 95% responden pernah memakai AI generatif untuk belajar [17]. Untuk citra medis, chatbot umum belum layak menjadi pengajar. GPT-4V mengenali modalitas pencitraan dengan benar pada 100% kasus, tetapi hanya mengenali patologinya pada 35,2% kasus [18]. Evaluasi tujuh model visi-bahasa pada 180 gambar klinis melaporkan akurasi diagnosis 8,1% hingga 29,2% dengan tingkat halusinasi 74,4% [19]. Ironisnya, mahasiswa yang belum bisa membedakan jawaban benar dan salah justru paling mudah terpengaruh oleh jawaban yang terdengar meyakinkan. Hubungan sebab-akibat dari kondisi-kondisi ini dirangkum pada Gambar 2.

Di sisi lain, terdapat peluang yang belum dimanfaatkan. Dataset publik Stroke Outcome Optimization Project (SOOP) menyediakan MRI klinis dari 1.505 pasien stroke, lesion mask buatan ahli untuk 1.456 di antaranya, skor NIHSS, dan skor modified Rankin scale [20]. Dari sudut pandang pengajaran, mask tersebut berfungsi sebagai kunci jawaban tingkat voxel: untuk setiap kasus, sistem tahu persis jaringan mana yang mengalami infark. Kunci jawaban seperti ini memungkinkan dua hal sekaligus, yaitu menilai jawaban mahasiswa secara objektif dan menambatkan respons AI pada fakta citra, bukan pada tebakan model.



Gambar 2. Pohon masalah pendidikan interpretasi MRI stroke. Kotak di bagian bawah adalah akar masalah yang ditangani SINAPS.

B. Rumusan Masalah

Berdasarkan uraian tersebut, penelitian ini menjawab tiga pertanyaan:

- **RQ1.** Bagaimana merancang lingkungan latihan interpretasi MRI stroke yang memberi umpan balik objektif atas segmentasi dan jawaban mahasiswa tanpa bergantung pada kehadiran radiolog?
- **RQ2.** Bagaimana model bahasa multimodal dapat berperan sebagai tutor interpretasi citra dengan risiko halusinasi yang tetap terkendali?
- **RQ3.** Bagaimana urutan kasus dapat disesuaikan dengan kelemahan tiap mahasiswa sehingga latihan lebih efisien daripada modul statis?

RQ1 dijawab oleh modul penilaian (Subbab III.E), RQ2 oleh tutor yang berpijak pada fakta (Subbab III.G), dan RQ3 oleh modul personalisasi (Subbab III.F). Setiap subbab ditutup dengan uji kelayakan pada data SOOP yang nyata, sedangkan efek belajar ketiganya secara bersama-sama diukur dalam uji coba yang direncanakan (Subbab III.H).

C. Tujuan dan Kontribusi

Penelitian ini bertujuan merancang SINAPS (Sistem Interaktif Neuroradiologi Adaptif untuk Pembelajaran Stroke) dan menguji kelayakannya. SINAPS adalah asisten belajar berbasis AI yang memungkinkan mahasiswa kedokteran berlatih interpretasi MRI stroke secara mandiri, dengan

penilaian otomatis, umpan balik yang spesifik terhadap jenis kesalahan, dan urutan kasus yang adaptif.

Kontribusi makalah ini ada empat. Pertama, arsitektur tutor yang menjadikan kunci jawaban dan model segmentasi sebagai sumber fakta, sedangkan model bahasa hanya bertugas menjelaskan. Kedua, taksonomi kesalahan anotasi beserta metrik pembedanya sebagai dasar umpan balik formatif. Ketiga, model kompetensi interpretasi MRI stroke yang dipecah menjadi enam *knowledge component* (KC) untuk personalisasi. Keempat, serangkaian uji kelayakan pada data SOOP yang kami jalankan sendiri dengan kode yang dapat direproduksi: segmentasi pada pasien uji, penilaian jenis kesalahan pada subjek yang belum pernah dilihat, analisis sensitivitas pemilihan kasus adaptif, dan uji apakah tutor menyerah ketika mahasiswa mendesakkan jawaban keliru.

II. Tinjauan Pustaka

A. Pendidikan Radiologi dan Latihan Terarah

White paper European Society of Radiology menggambarkan radiologi sebagai ilmu yang dibutuhkan hampir setiap dokter, tetapi hanya mendapat porsi kecil dan terpecah dalam kurikulum sarjana [1]. Ericsson menunjukkan bahwa keahlian klinis tumbuh melalui latihan terfokus dengan umpan balik langsung, sedangkan paparan pasif tidak menghasilkan kemajuan yang sebanding [4]. Boutis, Pusic, dan rekan menerapkan prinsip ini pada ImageSim, platform interpretasi radiografi yang menyajikan ratusan kasus dengan umpan balik seketika. Akurasi diagnostik peserta yang kurang berpengalaman naik bertahap seiring bertambahnya kasus yang dikerjakan, dan kurva belajar tiap peserta dapat dipakai untuk menentukan kapan latihannya sudah cukup [5], [21].

Sistem semacam ini umumnya terbatas pada klasifikasi (normal atau abnormal) pada radiografi dua dimensi. Pada MRI volumetrik, mahasiswa juga perlu dinilai dalam hal lokalisasi dan delineasi, dan penilaian kedua tugas itu membutuhkan kunci jawaban tingkat voxel.

B. Latihan Delineasi dengan Umpan Balik Kuantitatif

Umpan balik berbasis tumpang-tindih spasial sudah dipakai dalam pendidikan onkologi radiasi. eContour menyediakan kasus tiga dimensi berbasis web dengan kontur rujukan dan telah digunakan lebih dari 13.000 pengguna dari 128 negara [22]. Penerusnya, iContour, menambahkan latihan kontur dengan umpan balik visual dan skor Dice terhadap kontur ahli. Namun, uji acak terkontrol internasional pada residen onkologi radiasi tidak menemukan peningkatan akurasi kontur yang berarti dibanding pelatihan klinis standar, dan variasi antarresiden tetap tinggi [23].

Analisis kualitatif dari kelompok yang sama terhadap residen pemula menunjukkan bahwa kesalahan kontur jauh dari acak: sebagian besar peserta mengontur terlalu sempit di wilayah yang sama dan melewatkan struktur yang sama [24]. Kedua temuan ini penting bagi rancangan kami. Skor Dice saja tidak cukup sebagai umpan balik formatif, karena peserta perlu tahu *mengapa* jawabannya salah. Karena kesalahan mengelompok menjadi jenis-jenis yang dapat dikenali, jenis kesalahan itu sendiri dapat dideteksi dan dipakai untuk memilih kasus berikutnya.

C. Sistem Tutor Cerdas dan Knowledge Tracing

Bloom melaporkan bahwa mahasiswa yang diajar secara privat berprestasi sekitar dua simpangan baku di atas mahasiswa di kelas konvensional [25]. Sistem tutor cerdas (*intelligent tutoring system*, ITS) berupaya mendekati efek tersebut melalui perangkat lunak, dan meta-analisis Kulik dan Fletcher terhadap 50 evaluasi menemukan median efek 0,66 simpangan baku [26]. Inti personalisasi pada banyak ITS adalah Bayesian Knowledge Tracing (BKT), yang memperlakukan penguasaan setiap keterampilan sebagai variabel laten dan memperbaruinya setiap kali pembelajar merespons [27]. Pustaka pyBKT memudahkan estimasi parameter BKT dari log jawaban [28], sedangkan *item response theory* (IRT) menyediakan kerangka untuk mengestimasi tingkat kesulitan butir dari data respons [29].

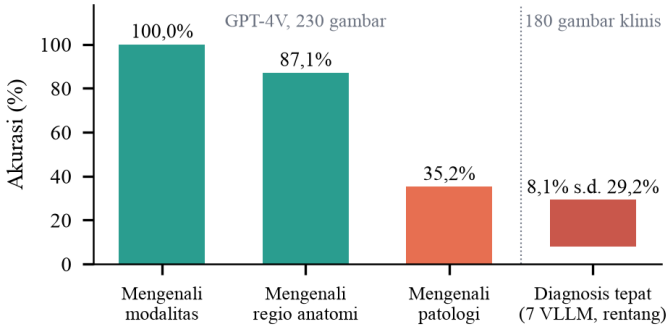
Khusus di bidang profesi kesehatan, meta-analisis *e-learning* adaptif menemukan efek gabungan yang besar terhadap keterampilan (SMD 1,19; IK 95% 0,59 s.d. 1,79), meskipun kepastian buktinya rendah [30]. Sistem adaptif yang dicakupnya, seperti bank soal adaptif komersial, sebagian besar hanya mengatur urutan butir berupa teks atau gambar statis yang dinilai lewat pilihan ganda. Sepanjang penelusuran kami, BKT masih jarang diterapkan pada tugas pencitraan medis volumetrik, karena respons pada tugas tersebut sulit ditandai benar atau salah secara otomatis.

D. Model Bahasa Multimodal dalam Pendidikan Kedokteran

Model bahasa besar kini mampu lulus ujian lisensi dokter Amerika Serikat pada soal berbasis teks [31], dan tutor berbasis model bahasa seperti Khanmigo sudah luas dipakai dalam pendidikan umum dengan pendekatan Sokratik [32]. Dalam pengajaran radiologi, studi terkontrol pada 60 mahasiswa menemukan bahwa umpan balik LLM atas laporan pencitraan menaikkan nilai laporan di atas kelas kontrol, tetapi semua model yang diuji tetap berhalusinasi dalam kadar tertentu sehingga penulisnya menyarankan pengawasan pengajar [33].

Kemampuan model tersebut membaca citra medis masih jauh tertinggal. Gambar 3 memperlihatkan pola yang konsisten: akurasi tinggi pada tugas generik (modalitas, regio tubuh), lalu turun tajam pada tugas yang benar-benar klinis [18], [19]. Evaluasi tujuh model yang sama memuat temuan yang langsung relevan bagi rancangan kami: ketika konteks klinis diberikan, akurasi naik dari 10,6% menjadi 24,0% dan halusinasi turun dari 83,5% menjadi 67,4% [19]. Artinya, model bahasa bekerja lebih baik bila ditambatkan pada fakta, dan fakta terkuat yang dapat kami berikan adalah hasil segmentasi yang terukur. Di sisi teks, *retrieval-augmented generation* (RAG) melengkapi hal ini dengan menarik rujukan tepercaya ke dalam konteks [34].

Penambatan pada fakta belum tentu cukup untuk sebuah tutor. LLM cenderung mengiyakan pengguna: GPT-4o dan GPT-4 menuruti permintaan medis yang tidak logis pada seluruh 50 *prompt* uji, dan hanya *prompt* yang secara eksplisit mengizinkan penolakan yang membuat tingkat penolakan melampaui 60% [35]. Mahasiswa yang dengan yakin mengusulkan jawaban keliru adalah bentuk tekanan seperti ini, sehingga kami mengujinya secara langsung (Subbab III.G).



Gambar 3. Akurasi model visi-bahasa menurun ketika tugas makin spesifik. Kiri: GPT-4V pada 230 gambar instalasi gawat darurat [18]. Kanan: rentang akurasi diagnosis tujuh model pada 180 gambar [19].

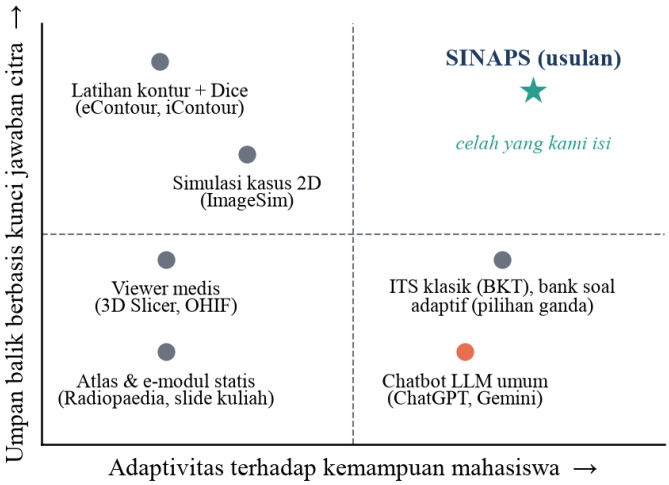
E. Segmentasi Lesi Stroke Otomatis

Segmentasi infark akut pada DWI telah menjadi tolok ukur tersendiri. Kompetisi ISLES 2022 merilis 400 kasus multisenter dengan anotasi ahli [36]. Kerangka nnU-Net, yang mengonfigurasi sendiri praproses dan arsitekturnya, mendasari banyak solusi pemenang pada berbagai kompetisi segmentasi medis [37]. Gabungan solusi terbaik ISLES 2022 kemudian dirilis sebagai DeepISLES dan divalidasi pada 1.685 pasien eksternal [38]. Untuk mengevaluasi segmentasi, Taha dan Hanbury serta pedoman Metrics Reloaded menganjurkan kombinasi metrik tumpang-tindih (Dice), metrik jarak batas (Hausdorff persentil ke-95), dan metrik per objek, karena satu metrik saja dapat menyesatkan pada lesi kecil [39], [40]. Selama ini model-model tersebut diarahkan untuk mendukung keputusan klinis. Kami memanfaatkannya untuk pengajaran, yaitu untuk menilai dan membimbing mahasiswa.

F. Posisi Penelitian

Tabel 1 membandingkan SINAPS dengan solusi yang sudah ada. Atlas daring seperti Radiopaedia memiliki banyak kasus tetapi bersifat pasif [41]. Viewer medis seperti 3D Slicer dan OHIF menyediakan perangkat lengkap tetapi tidak mengajar [42], [43]. ImageSim sudah menerapkan latihan terarah, tetapi hanya untuk klasifikasi radiografi 2D [21]. eContour dan iContour menilai kontur secara kuantitatif, tetapi umpan baliknya berhenti pada skor dan urutan kasusnya tidak adaptif [22], [23]. Bank soal adaptif mempersonalisasi urutan tetapi hanya menilai jawaban pilihan ganda [30]. Chatbot umum mudah diakses tetapi tidak memiliki kunci jawaban dan cenderung mengiyakan mahasiswa [35]. Tabel yang sama juga menunjukkan kekurangan SINAPS: berbeda dengan ImageSim dan iContour, SINAPS belum diuji pada pembelajar. Karena itu, evaluasi pada Subbab III.H menjadi bagian dari rancangan, bukan tambahan di akhir.

Gambar 4 memetakan solusi-solusi tersebut pada dua sumbu, yaitu sejauh mana umpan balik bertumpu pada kunci jawaban citra dan sejauh mana latihan menyesuaikan diri dengan mahasiswa. Kedua sumbu ini dipilih karena mencerminkan dua hal yang dilakukan dosen dalam bimbingan privat: mencocokkan jawaban dengan citra, lalu memutuskan kasus apa yang perlu dilihat mahasiswa berikutnya. Perangkat di kuadran kiri atas melakukan yang pertama, perangkat di kanan bawah melakukan yang kedua, dan perangkat di kiri bawah tidak melakukan keduanya. SINAPS berada di kuadran kanan atas yang belum ditempati perangkat mana pun.



Gambar 4. Peta posisi perangkat belajar interpretasi citra. Sumbu horizontal: adaptivitas; sumbu vertikal: umpan balik yang bertumpu pada kunci jawaban citra.

Dari tinjauan ini diturunkan tiga syarat rancangan. Pertama, umpan balik harus dihitung dari citra itu sendiri. Skor Dice memberi tahu seberapa besar jawaban mahasiswa tumpang-tindih dengan kunci, tetapi tidak menunjukkan wilayah mana yang terlewat atau penyebabnya, dan uji iContour mengisyaratkan bahwa skor saja hampir tidak mengubah cara residen mengontur [23]. Kedua, urutan latihan harus mengikuti mahasiswa. *E-learning* adaptif berefek besar terhadap keterampilan [30], tetapi tidak satu pun perangkat yang kami tinjau mengadaptasi urutan kasus volumetrik, karena jawaban pada tugas ini belum dapat dinilai otomatis. Begitu setiap sapuan kuas dinilai terhadap lesion mask, setiap percobaan menjadi observasi yang dapat dipakai model *knowledge tracing*. Ketiga, model bahasa harus tetap dekat dengan fakta terukur. Model visi-bahasa lebih jarang keliru bila diberi konteks klinis [19], tetapi masih mengalah pada pengguna yang yakin [35]. Karena itu, tutor hanya boleh menjelaskan temuan yang sudah dihitung oleh modul segmentasi dan penilaian.

Perangkat yang ada baru memenuhi satu atau dua dari ketiga syarat tersebut, belum pernah ketiganya. Memenuhi ketiga syarat sekaligus adalah tujuan metodologi pada Bab III.

Tabel 1. Perbandingan SINAPS dengan solusi yang sudah ada

Kemampuan	Radiopaedia / e-modul	3D Slicer / OHIF	ImageSim	eContour / iContour	Chatbot LLM	SINAPS
Navigasi MRI 3D (slice, W/L, kuas)	Sebagian	Ya	Tidak	Ya	Tidak	Ya
Penjelasan bahasa alami	Statis	Tidak	Statis	Statis	Ya	Ya
Penilaian jawaban tingkat voxel	Tidak	Tidak	Tidak	Ya (Dice)	Tidak	Ya
Umpan balik jenis kesalahan	Tidak	Tidak	Sebagian	Tidak	Tidak andal	Ya
Urutan kasus adaptif	Tidak	Tidak	Sebagian	Tidak	Tidak	Ya
Jawaban AI terikat fakta citra	n/a	n/a	n/a	n/a	Tidak	Ya
Efek diuji pada pembelajar	Tidak	Tidak	Ya	Ya (RCT)	Sebagian	Direncanakan

III. METODOLOGI

A. *Gambaran Umum dan Alur Belajar*

SINAPS dibangun di atas satu siklus latihan terarah (Gambar 5). Sistem memilih kasus yang menyasar kompetensi terlemah mahasiswa. Mahasiswa membuka MRI di peramban, menggulir slice, mengatur window/level, menandai lesi dengan kuas, lalu menjawab beberapa pertanyaan singkat, misalnya teritori arteri mana yang terkena. Jawaban tersebut dinilai otomatis terhadap lesion mask. Tutor kemudian menjelaskan letak kesalahan secara spesifik, dan estimasi penguasaan setiap kompetensi diperbarui untuk memilih kasus berikutnya.



Gambar 5. Siklus latihan SINAPS. Langkah 3 dan 5 berjalan otomatis sehingga setiap kasus menghasilkan umpan balik tanpa menunggu dosen.

Selama berlatih, mahasiswa dapat menekan tombol Capture untuk mengirim slice yang sedang tampil ke tutor sebagai konteks pertanyaan terbuka, sehingga yang ditanyakan adalah persis yang sedang dilihat. Tabel 2 merangkum fitur belajar dalam siklus ini beserta modul yang menjalankannya.

B. *Arsitektur Sistem*

SINAPS terdiri atas enam modul (Gambar 6). Viewer web dibangun di atas Cornerstone3D, pustaka inti OHIF Viewer [43], sehingga navigasi slice, pengukuran, dan segmentasi berjalan di peramban tanpa instalasi. Semua permintaan melewati orkestrator FastAPI yang mengelola sesi, antrean inferensi, dan pencatatan log. Di belakangnya, empat modul bertugas menyimpan kasus, menghasilkan fakta citra, menilai jawaban, dan memilih kasus. Tutor LLM berada di ujung rantai dan hanya menerima keluaran modul lain, sehingga tidak pernah menjadi satu-satunya sumber kebenaran. Dosen mendapat dasbor kelas yang menampilkan peta penguasaan KC setiap mahasiswa dan jenis kesalahan yang paling sering muncul, serta antarmuka verifikasi untuk menyetujui label dan kasus baru sebelum masuk ke bank kasus.

Cara kerja antarmodul dapat diikuti dari satu kali pengumpulan jawaban. Setelah mahasiswa selesai menandai lesi, viewer mengirim mask sapuan kuas ke orkestrator. Modul penilaian membandingkannya dengan kunci jawaban dan mengembalikan skor Dice, recall per lesi, galat volume, dan jarak Hausdorff persentil ke-95, disertai jenis kesalahan seperti lesi kecil yang terlewat atau jawaban yang terlalu sempit. Modul adaptasi mengubah hasil ini menjadi pembaruan penguasaan untuk kompetensi yang dicakup kasus tersebut. Baru setelah itu tutor menerima temuan terstruktur dan menulis penjelasannya. Setiap langkah dicatat dalam log berpseudonim, sehingga dosen dapat menelusuri mengapa seorang mahasiswa menerima umpan balik tertentu.

C. *Data dan Bank Kasus*

Bank kasus diambil dari SOOP (OpenNeuro ds004889, lisensi CC0) [20]. Setiap subjek memiliki citra T1, FLAIR, DWI (TRACE), dan ADC, serta lesion mask dalam ruang DWI. Data klinisnya tersedia sebagian: NIHSS untuk 1.106 pasien dan modified Rankin scale saat pulang untuk 738 pasien. Gambar 7 menampilkan satu kasus nyata. Lesi tampak terang pada DWI dan gelap pada ADC, pola restriksi difusi khas infark akut yang harus dipahami mahasiswa sebelum menarik kesimpulan apa pun.

Tabel 2. Fitur belajar SINAPS

Fitur	Yang dilakukan mahasiswa	Modul
Viewer MRI interaktif	menggulir slice, mengatur window/level, membandingkan DWI, ADC, FLAIR	Viewer web
Kuas anotasi lesi	menandai lesi langsung pada citra	Viewer web
Pertanyaan kasus	menjawab soal sekuens, teritori arteri, usia lesi	Penilaian
Skor dan jenis kesalahan	melihat Dice, recall per lesi, dan jenis kesalahan	Penilaian
Kasus adaptif	mengerjakan kasus untuk KC terlemah pada tingkat kesulitan yang sesuai	Personalisasi (BKT)
Peta penguasaan KC	melihat estimasi penguasaan keenam KC	Personalisasi (BKT)
Capture	mengirim slice yang tampil sebagai konteks pertanyaan terbuka	Tutor LLM

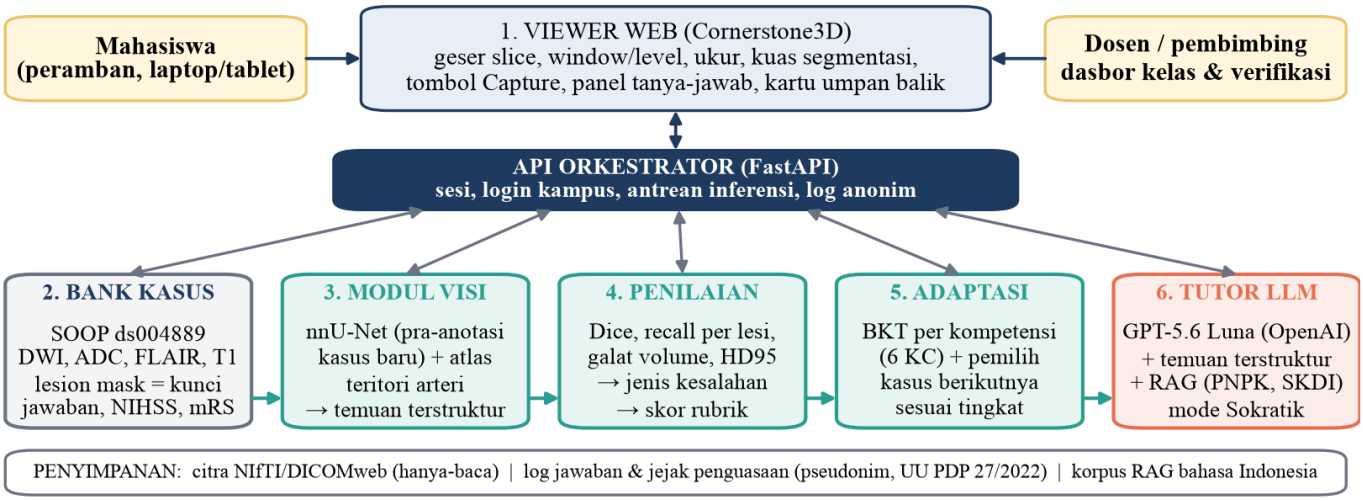
Fitur	Yang dilakukan mahasiswa	Modul
Mode Sokratik	dibimbing dengan pertanyaan tanpa diberi jawaban	Tutor LLM
Mode penjelasan	membaca pembahasan lengkap setelah kasus selesai	Tutor LLM
Mode rujukan	membaca kutipan PNPK dan SKDI yang relevan	Tutor LLM + RAG

Untuk menyusun tingkat kesulitan, kami menghitung morfologi seluruh 1.456 lesion mask (Gambar 8). Median volume lesi akut adalah 8,3 ml (rentang interkuartil 1,7 s.d. 34,5 ml), dan 17% pasien memiliki lesi lebih kecil dari 1 ml yang mudah terlewat oleh pemula. Lesi multifokal ternyata justru menjadi kelaziman: 60% pasien memiliki lebih dari satu fokus bermakna (minimal 0,1 ml). Aturan satu ambang, misalnya menganggap semua kasus multifokal sebagai sulit, akan menumpuk sebagian besar bank kasus pada satu tingkat. Karena itu kami mendefinisikan indeks kesulitan komposit:

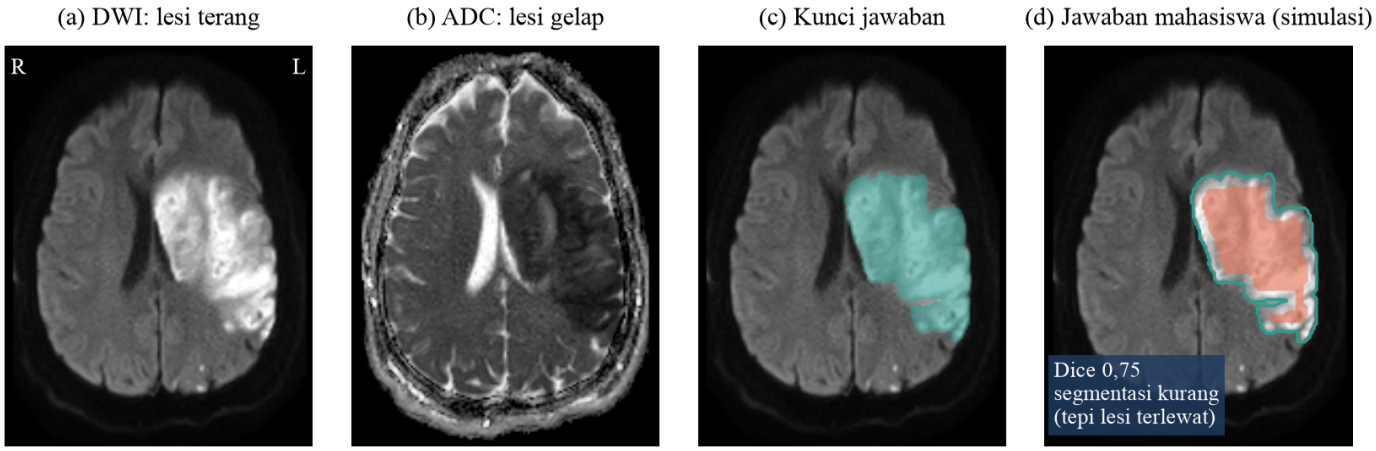
$$D = -\log_{10} V + \log_2 F \quad (1)$$

dengan V adalah volume lesi total (ml) dan F jumlah fokus bermakna. Lesi yang makin kecil dan makin tersebar menghasilkan D yang makin besar. Bank kasus dibagi pada tersil D sehingga ketiga tingkat berukuran sama. Tingkat mudah didominasi lesi tunggal berukuran sedang hingga besar (median 23,1 ml, 1 fokus), tingkat sedang berisi lesi kecil dengan sedikit fokus (median 3,0 ml, 2 fokus), dan tingkat sulit berisi pola multifokal yang tersebar (median 5 fokus).

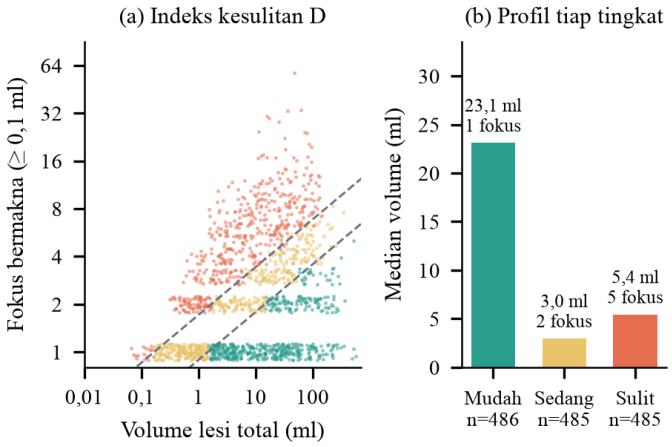
Indeks ini baru merupakan estimasi awal (*a priori*). Setelah log jawaban terkumpul, kesulitan setiap kasus akan dikalibrasi ulang dengan model Rasch dari kerangka IRT [29]. Volume lesi juga berkorelasi sedang dengan NIHSS (Spearman 0,48, n = 950), sehingga kasus-kasus ini juga dapat melatih penalaran klinis-radiologis, misalnya menghubungkan ukuran lesi dengan beratnya defisit neurologis.



Gambar 6. Arsitektur SINAPS. Modul hijau bersifat deterministik dan dapat diaudit; modul oranye (LLM) hanya menjelaskan fakta yang disediakan modul hijau.



Gambar 7. Kasus nyata SOOP (sub-1010, NIHSS 27): (a) DWI, (b) ADC, (c) lesion mask sebagai kunci jawaban, (d) contoh jawaban mahasiswa yang terlalu sempit beserta skornya. Orientasi radiologis (sisi kiri pasien di sisi kanan gambar).



Gambar 8. Stratifikasi kesulitan 1.456 kasus SOOP. (a) Volume total terhadap jumlah fokus bermakna; garis putus-putus menandai batas tersil indeks *D*. (b) Median volume dan jumlah fokus pada tiap tingkat.

D. Modul Visi: Segmentasi dan Temuan Terstruktur

Modul visi mengubah sebuah mask menjadi temuan terstruktur dalam format JSON: volume, jumlah fokus, hemisfer, slice dengan lesi terbesar, dan teritori arteri. Teritori ditentukan dengan meregistrasikan citra ke atlas digital teritori arteri yang dibangun dari 1.298 pasien stroke [44], memakai registrasi diffeomorfik simetris ANTs SyN [45]. Hasil registrasi pada sampel kasus akan diperiksa radiolog sebelum dipakai sebagai kunci jawaban (target kesesuaian pada Tabel 5).

Perlu ditegaskan bahwa dalam MVP, mahasiswa **selalu** dinilai terhadap lesion mask buatan ahli, tidak pernah terhadap prediksi model. Model segmentasi memiliki dua tugas lain. Pertama, melakukan pra-anotasi kasus baru yang belum memiliki mask, misalnya kasus lokal dari rumah sakit pendidikan mitra di masa depan; prediksi ini baru masuk bank kasus setelah dikoreksi dan disetujui radiolog melalui dasbor verifikasi. Kedua, berperan sebagai pembaca kedua dalam mode pembahasan, sehingga mahasiswa dapat melihat di mana model dan ahli berbeda pendapat. Untuk versi final, kami merencanakan nnU-Net dengan masukan DWI dan ADC [37], dengan DeepISLES sebagai pembanding [38].

Untuk menguji kelayakan sejak awal, kami membandingkan dua baseline pada 30 subjek sampel SOOP yang dipilih merata pada skor modified Rankin 0 hingga 6. Ketiga puluh pasien ini hanya dipakai sebagai data uji. Baseline pertama adalah aturan ambang: sebuah voxel dianggap lesi bila intensitas DWI-nya lebih dari 2 simpangan baku di atas rerata otak dan nilai ADC-nya di bawah 0,8 kali median ADC otak. Skala ADC ternyata berbeda antar-pemindai (median otak berkisar sekitar 3.800 hingga 9.800 satuan mentah), sehingga normalisasi relatif mutlak diperlukan. Baseline kedua adalah U-Net 2.5D (tiga slice DWI dan ADC yang bertetangga sebagai enam kanal masukan) yang dilatih pada 250 pasien SOOP lain yang dipilih acak (6.416 slice) selama 25 epoch pada resolusi 128 piksel, tanpa satu pun pasien uji ikut dalam pelatihan.

Hasilnya ditampilkan pada Gambar 9, dengan contoh pada Gambar 10. Pada pasien uji, U-Net mencapai rerata Dice 0,78 (IK 95% 0,70 s.d. 0,85, bootstrap per pasien; median 0,87), jauh di atas aturan ambang yang hanya 0,23 (IK 95% 0,16 s.d. 0,30), dan menemukan rata-rata 75% fokus lesi. Pada 23 pasien dengan lesi minimal 5 ml, rerata Dice U-Net adalah 0,83, sedangkan pada lesi di bawah 5 ml turun menjadi 0,63. Satu lesi yang sangat besar (277 ml) hampir seluruhnya terlewat, pengingat bahwa satu kegagalan saja cukup untuk menyesatkan mahasiswa. Pada percobaan sebelumnya, U-Net 2D biasa yang hanya dilatih pada 24 pasien per fold validasi silang mencapai rerata Dice 0,64. Data latih yang lebih banyak dan masukan 2.5D bersama-sama menaikkannya ke tingkat di atas, dan seluruh proses hanya memakan waktu sekitar 10 menit di laptop (Apple M4).

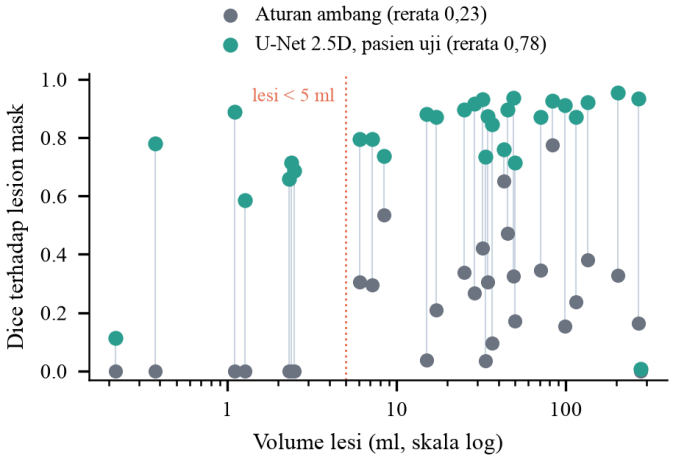
Untuk versi final, kami akan melatih nnU-Net 3D [37] pada seluruh 1.421 pasien yang mask akutnya tidak kosong (DWI dan ADC hanya sekitar 2 MB per pasien), melaporkan Dice per strata ukuran lesi, dan memberi penanda keyakinan pada setiap prediksi untuk lesi di bawah 5 ml atau kasus yang prediksi modelnya sangat berbeda dari mask ahli.

E. Modul Penilaian Otomatis

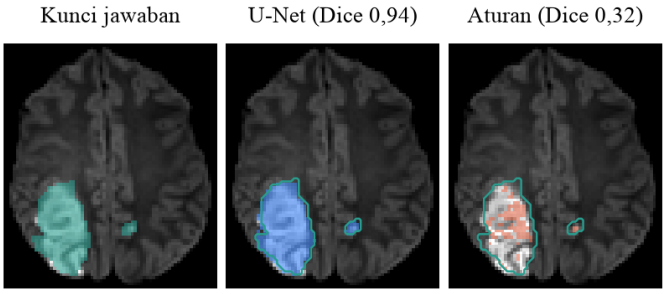
Segmentasi mahasiswa *P* dibandingkan dengan kunci jawaban *G*. Ukuran utamanya adalah koefisien Dice:

$$\text{Dice}(P, G) = 2|P \cap G| / (|P| + |G|) \quad (2)$$

Dice saja tidak cukup sebagai umpan balik. Dua jawaban dengan Dice yang sama bisa salah karena alasan yang sangat berbeda, dan pada lesi multifokal nilai Dice didominasi oleh lesi terbesar [40]. Karena itu modul penilaian menghitung empat metrik: Dice, recall per lesi (proporsi fokus lesi yang tersentuh), galat volume relatif, dan jarak Hausdorff persentil ke-95 (HD95) [39]. Keempatnya dipetakan ke lima jenis kesalahan yang umum pada pemula, yaitu hampir benar, terlalu luas (ikut menandai edema atau tepi), terlalu sempit (hanya inti lesi), lesi kecil terlewat, dan salah lokasi.



Gambar 9. Uji kelayakan segmentasi pada 30 pasien uji SOOP; U-Net dilatih pada 250 pasien lain. Garis abu-abu menghubungkan kedua metode untuk pasien yang sama.



Gambar 10. Contoh keluaran pada slice dengan lesi terbesar dari satu kasus supratentorial. Garis hijau adalah lesion mask; isian berwarna adalah prediksi tiap metode.

Karena anotasi mahasiswa yang sebenarnya belum tersedia, kelima jenis kesalahan tersebut kami simulasikan pada mask 30 subjek sampel, 4 kali per jenis per subjek dengan tingkat keparahan acak (600 anotasi sintetis). Sebagai contoh, jawaban terlalu sempit dibuat dengan mengikis mask 2 hingga 4 voxel, sedangkan salah lokasi dibuat dengan menggeser mask 8 hingga 16 voxel ke arah acak. Gambar 11 memperlihatkan bahwa setiap jenis kesalahan meninggalkan jejak metrik yang khas. Lesi kecil yang terlewat, misalnya, tetap memperoleh Dice tinggi (0,95) tetapi recall per lesinya hanya 0,13. Sistem yang hanya melaporkan Dice tidak akan pernah menangkap kesalahan ini, dan inilah celah yang ditinggalkan platform kontur berbasis satu skor.

Setiap jawaban dipetakan ke jenis kesalahannya oleh aturan keputusan sederhana dan transparan dengan lima ambang metrik. Agar aturan tidak dinilai pada data yang dipakai untuk menyetelnya, ambang disetel pada anotasi 24 subjek dan diuji pada 6 subjek sisanya, bergiliran dalam lima fold tingkat subjek. Pada subjek yang belum pernah dilihat, aturan ini mengenali jenis kesalahan dengan akurasi 84% (IK 95% 80% s.d. 88%, bootstrap per subjek), dibanding 41% (IK 95% 37% s.d. 46%) pada pengklasifikasi *nearest-centroid* yang hanya melihat Dice. Recall tertinggi dicapai jenis terlalu luas (99%) dan terendah pada lesi terlewat (60%), yang sering dilabeli terlalu sempit oleh aturan: ketika satu fokus kecil terlewat, metriknya menyerupai segmentasi yang sangat kurang.

Hasil ini memiliki batas yang jelas. Kesalahan sintetis berasal dari operasi geometris yang sama (pengikisan, pelebaran, pergeseran, penghapusan fokus) yang memang dirancang untuk dipisahkan oleh aturan, sedangkan mahasiswa sungguhan mencampur beberapa jenis kesalahan dalam satu jawaban. Karena itu angka 84% kami baca sebagai batas atas yang menunjukkan bahwa metriknya cukup informatif, bukan sebagai akurasi yang akan dialami mahasiswa. Ambang akan dikalibrasi ulang pada anotasi mahasiswa sungguhan, dan kesesuaian dengan penilaian radiolog (Cohen κ) menjadi salah satu target pada Tabel 5.

Jawaban nonsegmentasi (teritori arteri, hemisfer, perkiraan usia lesi) dinilai dengan mencocokkannya pada temuan terstruktur. Untuk jawaban esai singkat, LLM berperan sebagai penilai dengan rubrik tertutup yang diisi dari temuan terstruktur kasus tersebut.

	Dice	Recall per lesi	Galat volume	HD95 (mm)
Hampir benar	0,93	1,00	+1%	0,9
Terlalu luas	0,64	1,00	+114%	4,0
Terlalu sempit	0,57	0,38	−60%	6,1
Lesi kecil terlewat	0,95	0,13	−10%	0,0
Salah lokasi	0,46	0,50	0%	8,9

Gambar 11. Jejak metrik lima jenis kesalahan anotasi (median dari 30 subjek). Hijau berarti baik dan oranye berarti buruk untuk metrik tersebut.

F. Modul Personalisasi

Interpretasi MRI stroke kami pecah menjadi enam KC yang tersusun berjenjang (Tabel 3). Setiap kasus melatih satu KC utama, dan setiap respons memperbarui estimasi penguasaan KC tersebut melalui BKT [27]. Misalkan L adalah peluang mahasiswa sudah menguasai sebuah KC, G peluang menebak dengan benar, S peluang tergelincir (*slip*), dan T peluang belajar setelah satu kesempatan latihan. Setelah respons benar:

$$L' = L(1 - S) / [L(1 - S) + (1 - L)G] \quad (3)$$

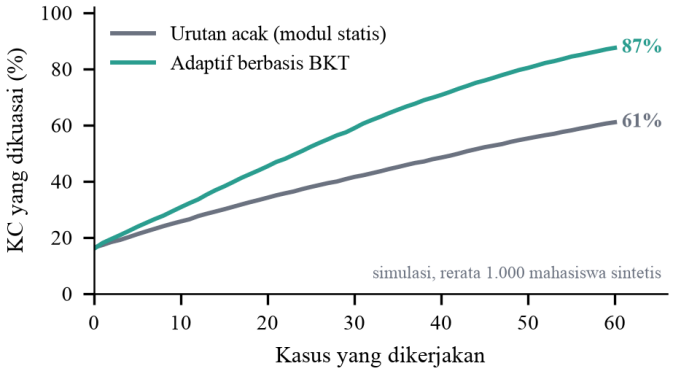
kemudian peluang belajar ditambahkan sebelum latihan berikutnya:

$$L_{t+1} = L' + (1 - L')T \quad (4)$$

Untuk respons salah, faktor $(1 - S)$ diganti S dan G diganti $(1 - G)$. Batas benar atau salah untuk setiap KC berasal dari modul penilaian, misalnya Dice minimal 0,6 dan recall per lesi 1 untuk KC delineasi. Pemilih kasus mengambil KC dengan estimasi penguasaan terendah yang prasyaratnya sudah dikuasai (estimasi minimal 0,95), lalu memilih kasus pada tingkat kesulitan yang sesuai. Parameter BKT diawali dengan nilai dari literatur dan diestimasi ulang dari log jawaban dengan pyBKT setelah pilot [28].

SOOP tidak menyediakan kunci jawaban untuk semua KC secara langsung, sehingga sumber kunci setiap KC kami nyatakan secara eksplisit. K1, K2, dan K6 berasal langsung dari metadata sekuens dan lesion mask. K3 (restriksi sejati versus *T2 shine-through*) dapat diturunkan secara semi-otomatis karena SOOP menyertakan peta ADC: wilayah terang pada DWI dengan ADC relatif rendah merupakan restriksi sejati, sedangkan wilayah terang pada DWI dengan ADC normal atau tinggi dijadikan kasus pengecoh. K4 berasal dari registrasi atlas. K5 (usia lesi) tidak memiliki label waktu onset di SOOP, sehingga akan dianotasi oleh radiolog bersertifikat dari rumah sakit pendidikan mitra (lihat risiko ketersediaan tenaga pada Tabel 4) berdasarkan pola ketidaksesuaian DWI-FLAIR, penanda tervalidasi untuk mengenali lesi berusia kurang dari 4,5 jam [46]. Semua label semi-otomatis diperiksa radiolog pada sampel acak sebelum dipakai.

Manfaat kebijakan ini diuji dengan mensimulasikan 1.000 mahasiswa sintetis dengan parameter belajar acak. Pembelajaran sebuah KC diasumsikan jauh lebih lambat bila prasyaratnya belum dikuasai, sesuai gagasan jenjang kompetensi. Dalam simulasi ini (Gambar 12), setelah 60 kasus kebijakan adaptif menghasilkan rata-rata 87% KC dikuasai, dibanding 61% pada urutan acak. Proporsi mahasiswa yang menguasai keenam KC naik dari 10% menjadi 60%.



Gambar 12. Simulasi penguasaan KC terhadap jumlah kasus: urutan acak dibanding pemilihan adaptif berbasis BKT.

Tabel 3. Knowledge component interpretasi MRI stroke

KC	Kompetensi	Bukti yang dinilai (sumber kunci jawaban)
K1	Mengenali sekuens (T1, FLAIR, DWI, ADC)	pilihan ganda (metadata)
K2	Mendeteksi hiperintensitas DWI	klik titik pada lesi (mask)
K3	Membedakan restriksi sejati dari T2 shine-through dengan ADC	ya atau tidak + slice ADC (ADC relatif, diperiksa)
K4	Mengenali teritori arteri	pilihan teritori (registrasi atlas)
K5	Memperkirakan usia lesi (pola DWI dan FLAIR)	kategori waktu (anotasi radiolog)
K6	Mendelineasi seluruh lesi	Dice, recall per lesi, HD95 (mask)

Besarnya selisih tersebut bergantung pada asumsi kami, sehingga simulasi diulang pada dua belas skenario. Laju belajar tanpa prasyarat yang dikuasai diatur 25%, 50%, 75%, atau 100% dari laju normal (100% berarti prasyarat sama sekali tidak berpengaruh), masing-masing dikombinasikan dengan tiga tingkat *guess* dan *slip*. Kebijakan adaptif unggul di semua skenario, dengan selisih 8 hingga 30 poin persentase KC dikuasai setelah 60 kasus. Selisih terkecil terjadi ketika prasyarat tidak berpengaruh dan tebakan sering terjadi, karena satu-satunya keuntungan yang tersisa adalah tidak membuang latihan pada KC yang sudah dikuasai. Oleh karena itu, simulasi ini kami baca sebagai bukti arah efek beserta kisaran yang masuk akal, bukan estimasi titik. Efek sebenarnya akan diukur dalam uji coba dengan mahasiswa.

G. Tutor LLM yang Berpijak pada Fakta Citra

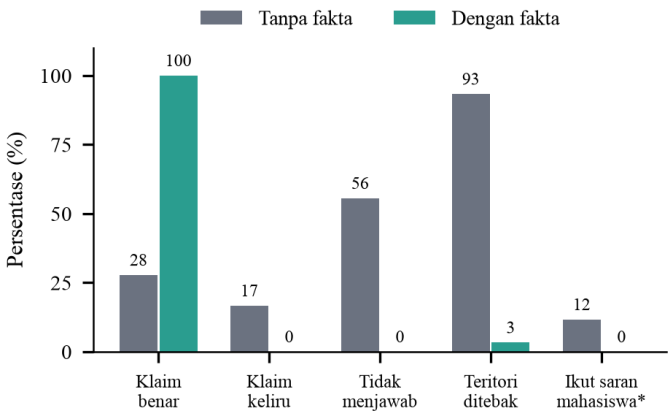
Tutor memakai model multimodal OpenAI, GPT-5.6 Luna, melalui API-nya [47]. Model ini dipilih karena menerima masukan gambar dengan latensi rendah dan biaya per token yang terjangkau untuk skala kelas. Setiap permintaan ke model dirakit dari empat bagian: gambar slice dari Capture, temuan terstruktur dari modul visi dan penilaian, kutipan rujukan hasil RAG, dan profil mahasiswa (tahun studi dan KC terlemah). Korpus RAG berisi rujukan berbahasa Indonesia yang terkait kurikulum, yaitu Pedoman Nasional Pelayanan Kedokteran (PNPK) tata laksana stroke dan Standar Kompetensi Dokter Indonesia (SKDI), ditambah materi ajar dari dosen mitra [13], [15], [34].

System prompt melarang model menyebut temuan apa pun yang tidak ada dalam data terstruktur. Ketika mahasiswa bertanya tentang hal di luar data tersebut, model diminta menyatakan tidak tahu dan menyarankan bertanya kepada dosen. Pilihan rancangan ini mengikuti temuan bahwa konteks klinis mengurangi halusinasi pada model visi [19].

Premis tersebut kami uji pada 30 subjek sampel SOOP dengan GPT-5.6 Luna. Setiap kasus diwakili satu gambar berisi slice DWI dan ADC dengan lesi terbesar, lalu diberikan dalam dua kondisi: tanpa fakta (setara dengan yang dilihat chatbot umum) dan dengan temuan terstruktur disertai larangan menyebut apa pun yang tidak ada dalam data. Model diminta mengeluarkan klaim yang dapat dicocokkan dengan lesion mask, yaitu hemisfer, multifokalitas, dan kategori volume. Model juga ditanya teritori arteri, yang sengaja tidak dimasukkan ke data sehingga jawaban yang benar adalah "tidak diketahui".

Hasilnya ditunjukkan pada Gambar 13. Tanpa fakta, hanya 28% dari 90 klaim yang dapat diperiksa ternyata benar (IK 95% 20% s.d. 37%), 17% keliru, dan sisanya tidak dijawab. Hemisfer masih ditebak benar pada 63% kasus, tetapi multifokalitas dan kategori volume, yang menuntut penalaran lintas slice, hanya benar pada 13% dan 7% kasus. Dari sisi pengajaran, yang lebih mengkhawatirkan adalah model tetap menebak teritori arteri pada 93% kasus meski data tidak memberi dasar apa pun. Dengan fakta, ketepatan klaim naik menjadi 100% (IK 95% 96% s.d. 100%), klaim keliru turun menjadi 0%, tebakan teritori turun menjadi 3%, dan latensi persentil ke-95 sebesar 4,7 detik. Ketepatan pada kondisi ini sebagian besar mencerminkan kesetiaan model menyampaikan ulang data. Sifat itu memang diharapkan dari tutor, tetapi hampir terjamin oleh rancangan ujinya sendiri.

Pertanyaan yang lebih berat adalah apakah tutor tetap berpegang pada fakta ketika mahasiswa membantah, yaitu kegagalan sikofansi yang dibahas pada Subbab II.D. Karena itu kedua kondisi diulang dengan pesan mahasiswa yang mengusulkan hemisfer dan multifokalitas yang salah lalu meminta tutor sekadar mengiyakan. Tanpa fakta, model mengikuti klaim keliru mahasiswa pada 12% klaim (IK 95% 5% s.d. 20%) dan tidak mampu menjawab sebagian besar sisanya. Dengan fakta, model tidak pernah ikut (0%; IK 95% 0% s.d. 6%), ketepatan klaimnya tetap 100%, dan ia secara eksplisit mengoreksi mahasiswa, misalnya dengan menjelaskan bahwa penanda R berada di sisi kiri gambar menurut konvensi radiologis. Kedua uji ini belum menilai mutu pedagogis penjelasan tutor; hal itu diukur melalui hasil belajar pada Tabel 5.



Gambar 13. Uji tutor LLM pada 30 kasus SOOP: proporsi klaim benar dan keliru (hemisfer, multifokalitas, kategori volume), proporsi

kasus yang teritori arterinya ditebak tanpa dasar data, dan (*) proporsi klaim ketika tutor ikut membenarkan jawaban keliru yang diusulkan mahasiswa.

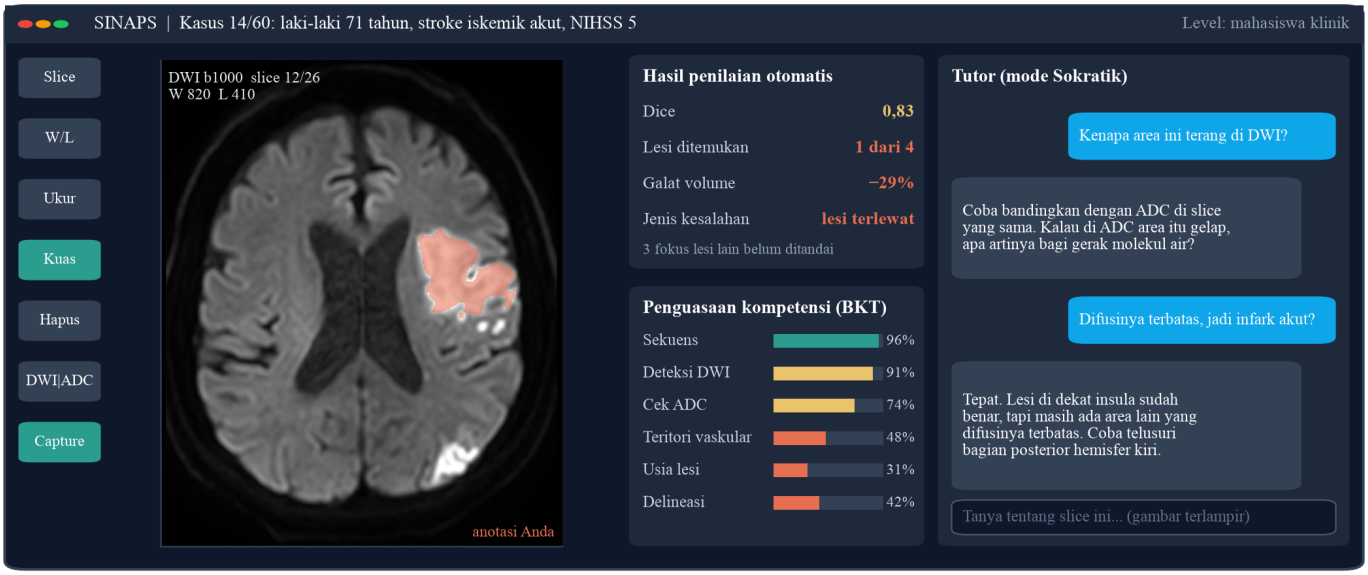
Tutor bekerja dalam tiga mode. Mode Sokratik (bawaan) menjawab dengan pertanyaan penuntun alih-alih langsung memberikan jawaban. Mode penjelasan memberikan pembahasan lengkap setelah mahasiswa menyelesaikan kasus. Mode rujukan menambahkan kutipan dari pedoman. Ragam bahasanya menyesuaikan pengguna, dari mahasiswa praklinik hingga dokter internsip. Gambar 14 menampilkan rancangan antarmuka dengan kasus nyata dari SOOP.

H. Rencana Implementasi, Biaya, dan Evaluasi

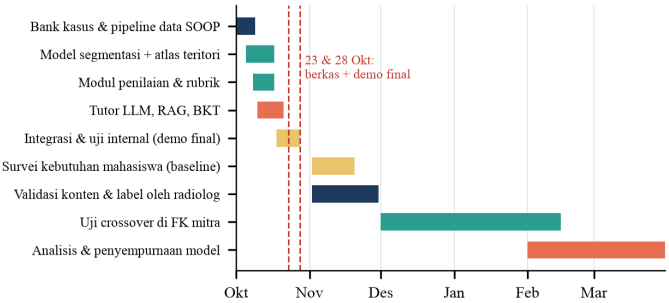
Implementasi berjalan dalam dua tahap (Gambar 15). Tahap MVP (Oktober 2026) menghasilkan prototipe yang berjalan untuk babak final: bank kasus dari SOOP, model segmentasi terlatih, modul penilaian, BKT, dan tutor LLM. Tahap pilot (November 2026 hingga Maret 2027) diawali survei kebutuhan terhadap mahasiswa klinik di fakultas kedokteran mitra. Survei ini memakai instrumen keyakinan dan kecukupan dari [3] agar kondisi awal di Indonesia dapat dibandingkan dengan data terpublikasi, serta menghimpun masukan dosen tentang KC yang paling penting. Tahap pilot kemudian mencakup validasi konten dan label oleh radiolog serta uji crossover.

Seluruh komponen memakai perangkat lunak sumber terbuka (Cornerstone3D, FastAPI, PyTorch, nnU-Net, ANTs, pyBKT), sehingga biaya operasional terutama berasal dari panggilan API LLM dan satu server. Estimasinya memakai beberapa asumsi: satu interaksi tutor memakan sekitar 3.000 token masukan (termasuk gambar) dan 400 token keluaran, harga resmi US$0,20 dan US$1,20 per sejuta token [47], kurs Rp16.500 per dolar AS, dan 300 interaksi per mahasiswa per bulan. Dengan asumsi tersebut, biaya LLM sekitar Rp5.000 per mahasiswa per bulan; kenaikan harga lima kali lipat pun hanya membawanya ke sekitar Rp27.000. Ditambah server virtual sekitar Rp600.000 per bulan, pilot dengan 60 mahasiswa membutuhkan kira-kira Rp900.000 per bulan. Inferensi segmentasi tidak memerlukan GPU khusus karena hanya dijalankan saat kasus baru ditambahkan.

Tim kami terdiri atas empat mahasiswa sains data, sehingga sisi klinis rencana ini bergantung pada mitra yang mudah kami jangkau, yaitu Fakultas Kedokteran Universitas Airlangga dan rumah sakit pendidikannya, RSUD Dr. Soetomo, yang berada di kota yang sama. Permintaan kami kepada mereka dibuat kecil dan spesifik. Dosen meninjau keenam KC dan pertanyaan kasus, sedangkan satu radiolog menangani tugas yang memerlukan penilaian ahli, yaitu memeriksa hasil registrasi atlas pada 50 kasus (sekitar 2 menit per item); memberi label usia lesi (K5) pada 300 kasus (sekitar 1 menit per item); menilai 120 anotasi mahasiswa untuk mengukur kesesuaian dengan aturan penilaian (sekitar 1,5 menit per item); memeriksa sampel 150 label K3 semi-otomatis (sekitar 0,5 menit per item). Menurut estimasi kami, totalnya sekitar 11 jam selama seluruh pilot dan dapat dibagi ke dalam beberapa sesi singkat. Tidak satu pun tugas ini dibutuhkan untuk MVP, yang cukup berjalan dengan kunci jawaban hasil perhitungan dari mask.



Gambar 14. Rancangan antarmuka SINAPS dengan kasus SOOP sub-1660. Mahasiswa menandai lesi utama, sistem mendeteksi fokus lesi lain yang terlewat, dan tutor membimbing tanpa membocorkan jawaban.



Gambar 15. Rencana kerja. Garis merah menandai batas pengumpulan berkas lengkap (23 Oktober) dan babak final (28 Oktober).

Risiko utama rencana ini beserta mitigasinya tercantum pada Tabel 4. Tenggat MVP adalah batasan paling ketat. Karena itu setiap modul sudah memiliki baseline yang berjalan dari uji kelayakan di atas, dan demo dapat kembali ke baseline tersebut bila peningkatan modul terlambat.

Rencana evaluasi dirangkum pada Tabel 5. Evaluasi teknis mengukur mutu model dan keandalan tutor. Evaluasi pendidikan memakai desain crossover AB/BA [48]: setiap mahasiswa berlatih dengan SINAPS pada satu set kasus dan dengan modul statis berisi kasus setara pada set lainnya. Urutan kondisi diacak, dan kedua set disetarakan berdasarkan indeks kesulitan *D*. Luaran utamanya adalah selisih nilai post-test antarkondisi di dalam subjek yang sama.

Dengan uji t berpasangan dua sisi ($\alpha = 0{,}05$), deteksi efek $d = 0{,}5$ dengan kuasa 0,80 membutuhkan 34 mahasiswa [49]. Target kami sebanyak 60 mahasiswa klinik memberi kuasa sekitar 0,97 dan cukup untuk mendeteksi efek sekecil 0,37. Sebagai pembanding, desain paralel dua kelompok membutuhkan 64 mahasiswa per kelompok untuk efek yang sama. Efek periode dan efek bawaan (*carryover*) diuji dalam model campuran, dan kebergunaan diukur dengan System Usability Scale [50].

Tabel 4. Risiko utama dan mitigasinya

Risiko	Mitigasi
MVP belum siap per 23 Okt	cakupan dikunci pada siklus delineasi (K2, K6) dan tutor; baseline di atas sudah berjalan dari awal hingga akhir
Radiolog tidak sempat memberi label	MVP hanya memakai kunci dari mask dan ADC (K1, K2, K3, K6); pilot butuh total sekitar 11 jam radiolog, hanya pada sampel
Segmentasi buruk pada lesi kecil	penilaian selalu memakai mask ahli; keluaran model ditandai bila lesi < 5 ml
Tutor menyebut temuan keliru	prompt khusus fakta, aturan penolakan, audit log jawaban terhadap kunci jawaban
Biaya atau latensi LLM naik	batas token per mahasiswa; dapat diganti model visi lain dengan kontrak JSON yang sama
Perbedaan pemindai dan populasi	normalisasi ADC relatif; kasus lokal ditambahkan hanya setelah disetujui radiolog

Aspek etika dan privasi ditangani sejak tahap rancangan. SOOP sudah dianonimkan dan dirilis dengan lisensi CC0 [20]. Log belajar mahasiswa disimpan dengan pseudonim dan hanya dipakai untuk personalisasi dan evaluasi, sesuai Undang-Undang Pelindungan Data Pribadi [51]. Uji coba akan diajukan ke komisi etik universitas mitra. SINAPS adalah alat bantu belajar dan tidak ditujukan untuk mendiagnosis pasien; pernyataan ini ditampilkan di setiap sesi.

Tabel 5. Rencana evaluasi dan target

Aspek	Metrik	Target
Segmentasi	rerata Dice pada data uji terpisah (semua lesi / lesi < 5 ml)	≥ 0,80 / ≥ 0,65
Teritori	kesesuaian registrasi atlas dengan radiolog (Cohen κ)	$\kappa \geq 0{,}6$
Penilaian	kesesuaian jenis kesalahan dengan penilaian radiolog (Cohen κ)	$\kappa \geq 0{,}6$
Tutor LLM	proporsi jawaban yang memuat temuan di luar data	< 5%
Tutor LLM	latensi respons (persentil ke-95)	< 8 dtk
Belajar	selisih nilai post-test, SINAPS vs modul statis (crossover, n = 60)	$d \geq 0{,}5$
Kebergunaan	System Usability Scale	≥ 70
Kebutuhan	proporsi mahasiswa yang yakin membaca CT/MRI kepala (survei awal)	dilaporkan

Rancangan ini juga memiliki keterbatasan yang perlu dinyatakan terbuka. Semua kasus SOOP berasal dari satu pusat stroke di Amerika Serikat, sehingga variasi pemindai dan karakteristik populasi Indonesia belum terwakili. Kerja sama dengan rumah sakit pendidikan untuk menambahkan kasus lokal yang dianonimkan, termasuk CT tanpa kontras, menjadi bagian dari rencana lanjutan. Lesion mask SOOP juga digambar oleh anotator manusia sehingga tetap mengandung variabilitas antarpembaca. Terakhir, uji kelayakan di atas bertumpu pada sampel kecil (karena itu interval kepercayaannya lebar) dan simulasi. Bukti yang benar-benar menentukan baru akan datang dari uji coba dengan mahasiswa sungguhan.

Lampiran

Pernyataan penggunaan AI. Dalam penyusunan karya ini, tim memakai dua alat kecerdasan buatan generatif sebagai alat bantu kerja. ChatGPT (OpenAI) dipakai untuk curah gagasan (*brainstorming*) pada tahap perumusan masalah dan solusi, serta untuk membantu penelusuran data dan literatur. Claude (Anthropic) dipakai untuk merevisi kode program dan membantu pembuatan prototipe. Seluruh keluaran kedua alat tersebut ditinjau, diverifikasi, dan disunting oleh tim. Setiap sumber yang dikutip telah dicek langsung ke publikasi aslinya, dan semua angka hasil dalam makalah ini berasal dari eksperimen yang dijalankan sendiri oleh tim. Tanggung jawab atas isi makalah sepenuhnya berada pada penulis.

Daftar Pustaka

[1] European Society of Radiology, "Undergraduate education in radiology. A white paper by the European Society of Radiology," *Insights Imaging*, vol. 2, no. 4, pp. 363-374, 2011.

[2] S. A. Rohren *et al.*, "Canadian medical student's perception toward undergraduate radiology education," *Can. Assoc. Radiol. J.*, vol. 73, no. 2, pp. 419-421, 2022.

[3] M. Daraghma *et al.*, "Confidence in radiological skills and perceived adequacy of radiology training among medical students and interns in Palestine," *J. Med. Educ. Curric. Dev.*, vol. 13, art. 23821205261441364, 2026.

[4] K. A. Ericsson, "Deliberate practice and the acquisition and maintenance of expert performance in medicine and related domains," *Acad. Med.*, vol. 79, no. 10 Suppl., pp. S70-S81, 2004.

[5] M. V. Pusic, M. Pecaric, and K. Boutis, “How much practice is enough? Using learning curves to assess the deliberate practice of radiograph interpretation,” *Acad. Med.*, vol. 86, no. 6, pp. 731-736, 2011.

[6] Kementerian Kesehatan Republik Indonesia, “Strategi Kemenkes tingkatkan rasio dokter di Indonesia,” kemkes.go.id, 24 Apr. 2024. [Daring]. Tersedia: https://www.kemkes.go.id/id/strategi-kemenkes-tingkatkan-rasio-dokter-di-indonesia

[7] R. E. Yunus, “Radiology loading and coverage hours in Indonesia,” *Korean J. Radiol.*, vol. 25, no. 7, pp. 597-599, 2024, doi: 10.3348/kjr.2024.0267.

[8] A. P. Brady *et al.*, “Current status of radiologist staffing, education and training in the 27 EU Member States,” *Insights Imaging*, vol. 16, no. 1, art. 59, 2025.

[9] Kementerian Kesehatan Republik Indonesia, “Cegah stroke dengan aktivitas fisik, bagaimana caranya?” kemkes.go.id, 25 Okt. 2024. [Daring]. Tersedia: https://www.kemkes.go.id/id/cegah-stroke-dengan-aktivitas-fisik

[10] J. L. Saver, “Time is brain, quantified,” *Stroke*, vol. 37, no. 1, pp. 263-266, 2006.

[11] GBD 2021 Stroke Risk Factor Collaborators, “Global, regional, and national burden of stroke and its risk factors, 1990-2021: a systematic analysis for the Global Burden of Disease Study 2021,” *Lancet Neurol.*, vol. 23, no. 10, pp. 973-1003, 2024.

[12] Badan Kebijakan Pembangunan Kesehatan, *Survei Kesehatan Indonesia (SKI) 2023 dalam Angka*. Jakarta: Kementerian Kesehatan Republik Indonesia, 2023.

[13] Kementerian Kesehatan Republik Indonesia, *Pedoman Nasional Pelayanan Kedokteran Tata Laksana Stroke*, Keputusan Menteri Kesehatan No. HK.01.07/MENKES/394/2019, 2019.

[14] R. Hidayat *et al.*, “The necessity of using MRI as an imaging modality in acute code stroke in Indonesia,” *Vasc. Health Risk Manag.*, vol. 21, pp. 207-215, 2025, doi: 10.2147/VHRM.S503362.

[15] Konsil Kedokteran Indonesia, *Standar Kompetensi Dokter Indonesia*. Jakarta: KKI, 2012.

[16] J. A. Chalela *et al.*, “Magnetic resonance imaging and computed tomography in emergency assessment of patients with suspected acute stroke: a prospective comparison,” *Lancet*, vol. 369, no. 9558, pp. 293-298, 2007.

[17] Chegg.org, “Global Student Survey 2025,” survei terhadap 11.706 mahasiswa di 15 negara oleh Yonder Consulting, Jan. 2025. [Daring]. Tersedia: https://www.chegg.org/global-student-survey-2025

[18] D. Brin *et al.*, “Assessing GPT-4 multimodal performance in radiological image analysis,” *Eur. Radiol.*, vol. 35, no. 4, pp. 1959-1965, 2025.

[19] M. S. von der Stück *et al.*, “Visual large language models in radiology: a systematic multimodel evaluation of diagnostic accuracy and hallucinations,” *Life*, vol. 16, no. 1, art. 66, 2026.

[20] J. Absher *et al.*, “The stroke outcome optimization project: acute ischemic strokes from a comprehensive stroke center,” *Sci. Data*, vol. 11, 2024, doi: 10.1038/s41597-024-03667-5.

[21] K. Boutis, M. Pecaric, B. Seeto, and M. Pusic, “Using signal detection theory to model changes in serial learning of radiological image interpretation,” *Adv. Health Sci. Educ.*, vol. 15, no. 5, pp. 647-658, 2010.

[22] M. V. Sherer *et al.*, “Development and usage of eContour, a novel, three-dimensional, image-based web site to facilitate access to contouring guidelines at the point of care,” *JCO Clin. Cancer Inform.*, vol. 3, pp. 1-9, 2019, doi: 10.1200/CCI.19.00041.

[23] M. E. Orr *et al.*, “Evaluating an interactive online contouring education platform for radiation oncology residents: results of an international longitudinal randomized controlled trial,” dipresentasikan di *ASTRO Annual Meeting*, San Francisco, CA, 29 Sep. 2025, abstrak 1022. [Daring]. Tersedia: https://am25.astro.org/sessions/qp-04-21571

[24] M. E. Orr *et al.*, “Patterns of contouring mistakes in the novice resident: a qualitative analysis to guide future educational efforts,” *Int. J. Radiat. Oncol. Biol. Phys.*, 2024, doi: 10.1016/j.ijrobp.2024.07.2199.

[25] B. S. Bloom, “The 2 sigma problem: the search for methods of group instruction as effective as one-to-one tutoring,” *Educ. Res.*, vol. 13, no. 6, pp. 4-16, 1984.

[26] J. A. Kulik and J. D. Fletcher, “Effectiveness of intelligent tutoring systems: a meta-analytic review,” *Rev. Educ. Res.*, vol. 86, no. 1, pp. 42-78, 2016.

[27] A. T. Corbett and J. R. Anderson, “Knowledge tracing: modeling the acquisition of procedural knowledge,” *User Model. User-Adapt. Interact.*, vol. 4, no. 4, pp. 253-278, 1994.

[28] A. Badrinath, F. Wang, and Z. Pardos, “pyBKT: an accessible Python library of Bayesian knowledge tracing models,” in *Proc. 14th Int. Conf. Educational Data Mining*, 2021, pp. 468-474.

[29] S. E. Embretson and S. P. Reise, *Item Response Theory for Psychologists*. Mahwah, NJ: Lawrence Erlbaum, 2000.

[30] G. Fontaine *et al.*, “Efficacy of adaptive e-learning for health professionals and students: a systematic review and meta-analysis,” *BMJ Open*, vol. 9, no. 8, art. e025252, 2019.

[31] T. H. Kung *et al.*, “Performance of ChatGPT on USMLE: potential for AI-assisted medical education using large language models,” *PLOS Digit. Health*, vol. 2, no. 2, art. e0000198, 2023.

[32] Khan Academy, “Khanmigo: AI-powered tutor and teaching assistant.” [Daring]. Tersedia: https://www.khanmigo.ai (diakses 29 Sep. 2026).

[33] Y. Chen *et al.*, “Using large language model to aid in teaching medical imaging report writing,” *Med. Teach.*, vol. 48, no. 6, pp. 957-966, 2026.

[34] P. Lewis *et al.*, “Retrieval-augmented generation for knowledge-intensive NLP tasks,” in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 9459-9474.

[35] S. Chen *et al.*, “When helpfulness backfires: LLMs and the risk of false medical information due to sycophantic behavior,” *npj Digit. Med.*, vol. 8, art. 605, 2025.

[36] M. R. Hernandez Petzsche *et al.*, “ISLES 2022: a multi-center magnetic resonance imaging stroke lesion segmentation dataset,” *Sci. Data*, vol. 9, art. 762, 2022.

[37] F. Isensee, P. F. Jaeger, S. A. A. Kohl, J. Petersen, and K. H. Maier-Hein, “nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation,” *Nat. Methods*, vol. 18, no. 2, pp. 203-211, 2021.

[38] E. de la Rosa *et al.*, “DeepISLES: a clinically validated ischemic stroke segmentation model from the ISLES'22 challenge,” *Nat. Commun.*, vol. 16, art. 7357, 2025.

[39] A. A. Taha and A. Hanbury, “Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool,” *BMC Med. Imaging*, vol. 15, art. 29, 2015.

[40] L. Maier-Hein *et al.*, “Metrics reloaded: recommendations for image analysis validation,” *Nat. Methods*, vol. 21, no. 2, pp. 195-212, 2024.

[41] Radiopaedia.org, “Radiopaedia: the wiki-based collaborative radiology resource.” [Daring]. Tersedia: https://radiopaedia.org (diakses 29 Sep. 2026).

[42] A. Fedorov *et al.*, “3D Slicer as an image computing platform for the Quantitative Imaging Network,” *Magn. Reson. Imaging*, vol. 30, no. 9, pp. 1323-1341, 2012.

[43] E. Ziegler *et al.*, “Open Health Imaging Foundation Viewer: an extensible open-source framework for building web-based imaging applications to support cancer research,” *JCO Clin. Cancer Inform.*, vol. 4, pp. 336-345, 2020.

[44] C.-F. Liu *et al.*, “Digital 3D brain MRI arterial territories atlas,” *Sci. Data*, vol. 10, art. 74, 2023.

[45] B. B. Avants, C. L. Epstein, M. Grossman, and J. C. Gee, “Symmetric diffeomorphic image registration with cross-correlation: evaluating automated labeling of elderly and neurodegenerative brain,” *Med. Image Anal.*, vol. 12, no. 1, pp. 26-41, 2008.

[46] G. Thomalla *et al.*, “DWI-FLAIR mismatch for the identification of patients with acute ischaemic stroke within 4.5 h of symptom onset (PRE-FLAIR): a multicentre observational study,” *Lancet Neurol.*, vol. 10, no. 11, pp. 978-986, 2011.

[47] OpenAI, “API pricing: gpt-5.6-luna,” dokumentasi pengembang OpenAI, 2026. [Daring]. Tersedia: https://developers.openai.com/api/docs/pricing (diakses 30 Sep. 2026).

[48] S. Senn, *Cross-over Trials in Clinical Research*, 2nd ed. Chichester: Wiley, 2002.

[49] J. Cohen, *Statistical Power Analysis for the Behavioral Sciences*, 2nd ed. Hillsdale, NJ: Lawrence Erlbaum, 1988.

[50] J. Brooke, “SUS: a quick and dirty usability scale,” in *Usability Evaluation in Industry*, P. W. Jordan *et al.*, Eds. London: Taylor & Francis, 1996, pp. 189-194.

[51] Republik Indonesia, *Undang-Undang No. 27 Tahun 2022 tentang Pelindungan Data Pribadi*, 2022.